

# 最小二乗法とベイズ推定

中野 慎也

「データ科学: 理論から実用へ」

7 September 2023

# まず時間発展を考慮しない場合について


- データ同化でやりたいことは、

$$x_k = f_k(x_{k-1}) + v_k,$$

$$y_k = H_k x_k + w_k$$

の 2 種類の関係式が与えられ、更に各時刻の観測データ  $y_k$  が与えられたという条件の下で、各時刻の  $x_k$  を推定することであった。

- しかし、まずはシステムモデル  $x_k = f_k(x_{k-1}) + v_k$  は無視し、各時間ステップで、観測  $y$  が与えられた下で  $y_k = H_k x_k + w_k$  という観測モデルに基づいて  $x$  を推定するという問題を考える。



# まず時間発展を考慮しない場合について


- データ同化でやりたいことは、

$$x_k = f_k(x_{k-1}) + v_k,$$

$$y_k = H_k x_k + w_k$$

の2種類の関係式が与えられ、更に各時刻の観測データ  $y_k$  が与えられたという条件の下で、各時刻の  $x_k$  を推定することであった。

- しかし、まずはシステムモデル  $x_k = f_k(x_{k-1}) + v_k$  は無視し、各時間ステップで、観測  $y$  が与えられた下で  $y_k = H_k x_k + w_k$  という観測モデルに基づいて  $x$  を推定するという問題を考える。



# 最小二乗法

- まずは,  $y = Hx + w$  において,  $\|w\|^2$  をなるべく小さくするという方針を考える. それはつまり,

$$\|y - Hx\|^2$$

を最小化する問題で, 所謂最小二乗法である.

- データ数  $n$  が未知変数の数  $m$  よりも多い場合 ( $n > m$ ) には, 「基本的に」これで  $x$  が決まる.

# 最小二乗法

$$\Psi_L = \|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2 = \sum_{i=1}^n \left( y_i - \sum_{j=1}^m H_{ij}x_j \right)^2 \quad (1)$$

とおくと,

$$\frac{\partial \Psi_L}{\partial x_k} = -2 \sum_{i=1}^n H_{ik} \left( y_i - \sum_{j=1}^m H_{ij}x_j \right) = 0 \quad (2)$$

なので,

$$-\mathbf{H}^\top \mathbf{y} + \mathbf{H}^\top \mathbf{H} \mathbf{x} = 0. \quad (3)$$

したがって,  $\mathbf{H}^\top \mathbf{H}$  が正則 (逆行列を持つ) なら


$$\hat{\mathbf{x}} = (\mathbf{H}^\top \mathbf{H})^{-1} \mathbf{H}^\top \mathbf{y}. \quad (4)$$

# 最小二乗法の例 (直線あてはめ)

変数  $z$  の列  $\{z_1, z_2, \dots, z_n\}$  に対して, 変数  $y$  に関するデータ  $\{y_1, y_2, \dots, y_n\}$  が得られているとき,  $y$  を

$$y = a_0 + a_1 z + \varepsilon \quad (5)$$

という式で説明する.



$$\mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}, \quad \mathbf{H} = \begin{pmatrix} 1 & z_1 \\ \vdots & \vdots \\ 1 & z_n \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} a_0 \\ a_1 \end{pmatrix}, \quad \mathbf{w} = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

とおくと, 先程の  $y = \mathbf{H}\mathbf{x} + \mathbf{w}$  の形になる.

# 最小二乗法の例 (直線あてはめ)

$$\mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}, \quad \mathbf{H} = \begin{pmatrix} 1 & z_1 \\ \vdots & \vdots \\ 1 & z_n \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} a_0 \\ a_1 \end{pmatrix}, \quad \mathbf{w} = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

に対して、推定式  $\hat{\mathbf{x}} = (\mathbf{H}^\top \mathbf{H})^{-1} \mathbf{H}^\top \mathbf{y}$  を適用する。

$\bar{z} = \sum z_i / n$ ,  $\bar{y} = \sum y_i / n$  として,

$$\mathbf{H}^\top \mathbf{H} = \begin{pmatrix} n & \sum z_i \\ \sum z_i & \sum z_i^2 \end{pmatrix} = \begin{pmatrix} n & n\bar{z} \\ n\bar{z} & \sum z_i^2 \end{pmatrix},$$

$$\mathbf{H}^\top \mathbf{y} = \begin{pmatrix} \sum y_i \\ \sum z_i y_i \end{pmatrix} = \begin{pmatrix} n\bar{y} \\ \sum z_i y_i \end{pmatrix}.$$

# 最小二乗法の例 (直線あてはめ)

$$\begin{aligned}
 \hat{\mathbf{x}} &= (\mathbf{H}^\top \mathbf{H})^{-1} \mathbf{H}^\top \mathbf{y} = \frac{1}{n \sum z_i^2 - n^2 \bar{z}^2} \begin{pmatrix} \sum z_i^2 & -n\bar{z} \\ -n\bar{z} & n \end{pmatrix} \begin{pmatrix} n\bar{y} \\ \sum z_i y_i \end{pmatrix} \\
 &= \frac{1}{n^2 C_{zz}} \begin{pmatrix} n\bar{y} \sum z_i^2 - n\bar{z} \sum z_i y_i \\ n \sum z_i y_i - n^2 \bar{z} \bar{y} \end{pmatrix} \\
 &= \frac{1}{n^2 C_{zz}} \begin{pmatrix} n\bar{y} \sum z_i^2 - n^2 \bar{z}^2 \bar{y} - n\bar{z} (\sum z_i y_i - n\bar{z} \bar{y}) \\ n^2 C_{zy} \end{pmatrix} \\
 &= \frac{1}{C_{zz}} \begin{pmatrix} \bar{y} C_{zz} - \bar{z} C_{zy} \\ C_{zy} \end{pmatrix} = \begin{pmatrix} \bar{y} - \bar{z} (C_{zy}/C_{zz}) \\ C_{zy}/C_{zz} \end{pmatrix}
 \end{aligned} \tag{6}$$

但し,

$$C_{zz} = \frac{1}{n} \sum z_i^2 - \bar{z}^2, \quad C_{zy} = \frac{1}{n} \sum z_i y_i - \bar{z} \bar{y}.$$



# 特異値分解による方法

$\Psi_L = \|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2$  を最小化する  $\mathbf{x}$  は、特異値分解を使って得ることもできる。

まずは、 $\mathbf{H}$  を以下のように特異値分解する:

$$\mathbf{H} = \check{\mathbf{U}}\check{\mathbf{\Lambda}}\check{\mathbf{V}}^\top = \sum_{i=1}^r \lambda_i \mathbf{u}_i \mathbf{v}_i^\top. \quad (7)$$

また、 $\{\mathbf{v}_1, \dots, \mathbf{v}_m\}$ ,  $\{\mathbf{u}_1, \dots, \mathbf{u}_n\}$  はそれぞれ  $\mathbf{x}$ ,  $\mathbf{y}$  が定義されるベクトル空間の正規直交基底なので、

$$\mathbf{x} = \sum_{i=1}^m \alpha_i \mathbf{v}_i, \quad \mathbf{y} = \sum_{i=1}^n \beta_i \mathbf{u}_i \quad (8)$$

と書くことができる。但し、各  $i$  に対して  $\alpha_i = \mathbf{v}_i^\top \mathbf{x}$ ,  $\beta_i = \mathbf{u}_i^\top \mathbf{y}$ 。

これを使って、 $\Psi_L = \|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2$  を計算する。

# 特異値分解による方法

計算してみると,

$$\begin{aligned}
 \Psi_L = \|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2 &= \left\| \sum_{i=1}^n \beta_i \mathbf{u}_i - \left( \sum_{i=1}^r \lambda_i \mathbf{u}_i \mathbf{v}_i^\top \right) \left( \sum_{i=1}^m \alpha_i \mathbf{v}_i \right) \right\|^2 \\
 &= \left\| \sum_{i=1}^n \beta_i \mathbf{u}_i - \sum_{i=1}^r \lambda_i \alpha_i \mathbf{u}_i \right\|^2 \\
 &= \left\| \sum_{i=1}^r (\beta_i - \lambda_i \alpha_i) \mathbf{u}_i + \sum_{i=r+1}^n \beta_i \mathbf{u}_i \right\|^2 \\
 &= \sum_{i=1}^r (\beta_i - \lambda_i \alpha_i)^2 + \sum_{i=r+1}^n \beta_i^2.
 \end{aligned} \tag{9}$$

$r = m (= \dim \mathbf{x})$  の場合,  $\alpha_i = \beta_i / \lambda_i$  ( $1 \leq i \leq r$ ) とすればよく,

$$\hat{\mathbf{x}} = \operatorname{argmin}_{\mathbf{x}} \|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2 = \sum_{i=1}^m \frac{\beta_i}{\lambda_i} \mathbf{v}_i. \tag{10}$$

# 特異値分解による方法

先に得られた推定値  $\hat{x} = (\mathbf{H}^\top \mathbf{H})^{-1} \mathbf{H}^\top \mathbf{y}$  は,  $r = m \leq n$  のとき

$$(\mathbf{H}^\top \mathbf{H})^{-1} = (\mathbf{V} \mathbf{\Lambda} \mathbf{U}^\top \mathbf{U} \mathbf{\Lambda} \mathbf{V}^\top)^{-1} = (\mathbf{V} \mathbf{\Lambda}^2 \mathbf{V}^\top)^{-1} = (\mathbf{V} \mathbf{\Lambda}^{-2} \mathbf{V}^\top) = \sum_{i=1}^m \frac{1}{\lambda_i^2} \mathbf{v}_i \mathbf{v}_i^\top \quad (11)$$

となり,

$$\mathbf{H}^\top \mathbf{y} = \left( \sum_{i=1}^m \lambda_i \mathbf{v}_i \mathbf{u}_i^\top \right) \left( \sum_{j=1}^m \beta_j \mathbf{u}_j \right) = \sum_{i=1}^m \lambda_i \beta_i \mathbf{v}_i \quad (12)$$

となることから,

$$(\mathbf{H}^\top \mathbf{H})^{-1} \mathbf{H}^\top \mathbf{y} = \left( \sum_{i=1}^m \frac{1}{\lambda_i^2} \mathbf{v}_i \mathbf{v}_i^\top \right) \left( \sum_{i=1}^m \lambda_i \beta_i \mathbf{v}_i \right) = \sum_{i=1}^m \frac{\beta_i}{\lambda_i} \mathbf{v}_i. \quad (13)$$

つまり, 特異値分解で求めた式と等価であることが分かる.

なお,  $\mathbf{H}^\top \mathbf{H}$  が逆行列を持つという条件は,  $r = m$  という条件と対応している.

# ムーア・ペンローズ一般逆行列

$$\hat{x} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y}. \quad (14)$$

の  $(\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T$  の部分は、 $\mathbf{H}$  のムーア・ペンローズ一般逆行列になっている。

実際、 $\mathbf{H}$  の特異値分解を

$$\mathbf{H} = \check{\mathbf{U}} \check{\mathbf{\Lambda}} \check{\mathbf{V}}^T$$

として、計算すると、

$$\begin{aligned} (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T &= (\check{\mathbf{V}} \check{\mathbf{\Lambda}} \check{\mathbf{U}}^T \check{\mathbf{U}} \check{\mathbf{\Lambda}} \check{\mathbf{V}}^T)^{-1} \check{\mathbf{V}} \check{\mathbf{\Lambda}} \check{\mathbf{U}}^T = (\check{\mathbf{V}} \check{\mathbf{\Lambda}}^2 \check{\mathbf{V}}^T)^{-1} \check{\mathbf{U}} \check{\mathbf{\Lambda}} \check{\mathbf{V}}^T \\ &= \check{\mathbf{V}} \check{\mathbf{\Lambda}}^{-2} \check{\mathbf{V}}^T \check{\mathbf{V}} \check{\mathbf{\Lambda}} \check{\mathbf{U}}^T = \check{\mathbf{V}} \check{\mathbf{\Lambda}}^{-2} \check{\mathbf{\Lambda}} \check{\mathbf{U}}^T = \check{\mathbf{V}} \check{\mathbf{\Lambda}}^{-1} \check{\mathbf{U}}^T \end{aligned} \quad (15)$$

# 特異値分解による方法

- 特異値分解から得られた結果

$$\hat{x} = \sum_{i=1}^r \frac{\beta_i}{\lambda_i} \mathbf{v}_i \quad (16)$$

より、 $\lambda_i$  が小さい場合、 $x$  の推定値は  $\beta_i$  に大きく影響されることも分かる。

- $\beta_i$  に誤差がある場合、その誤差の  $\hat{x}$  への影響が大きく増幅されるため、安定した解が得られない。
- $\hat{x}$  を安定させるため、

$$\hat{x} = \sum_{i=1}^l \frac{\beta_i}{\lambda_i} \mathbf{v}_i$$

$$(\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_l > \varepsilon \geq \lambda_{l+1} \geq \cdots \lambda_r > 0),$$

のように特異値の小さい成分を落とす場合もある。

## $r < m \leq n$ の場合

$r < m \leq n$  の場合,  $\alpha_{r+1} \dots \alpha_m$  は  $\Psi_L = \|y - Hx\|^2$  に影響せず,

$$\hat{x} = \sum_{i=1}^r \frac{\beta_i}{\lambda_i} v_i + \sum_{i=r+1}^m \alpha_i v_i.$$

の形であればよい.

この式から以下のことが分かる:

- $H$  を介した観測  $y$  から,  $x$  のうち  $\{v_{r+1}, \dots, v_m\}$  の成分に関する情報を得ることはできない.
- $\{\alpha_{r+1}, \dots, \alpha_m\}$  が決まらないため,  $\Psi_L$  を最小化する解は一意には求まらない.

# ノルム最小解

$r < m \leq n$  の場合の式

$$\hat{\mathbf{x}} = \sum_{i=1}^r \frac{\beta_i}{\lambda_i} \mathbf{v}_i + \sum_{i=r+1}^m \alpha_i \mathbf{v}_i.$$

において、 $\alpha_i = 0$  ( $i > r$ ) と置いた

$$\hat{\mathbf{x}} = \sum_{i=1}^r \frac{\beta_i}{\lambda_i} \mathbf{v}_i \quad (17)$$

は、 $\Psi_L = \|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2$  を最小化する  $\mathbf{x}$  のうち、ノルムが最小となる解を与え、ノルム最小解と呼ばれる。

$r \leq n < m$  の場合もノルム最小解

$$\hat{\mathbf{x}} = \sum_{i=1}^r \frac{\beta_i}{\lambda_i} \mathbf{v}_i \quad (18)$$

が考えられ、 $\Psi_L$  を最小にする  $\mathbf{x}$  のうち、ノルムを最小とする解を与える。

# 予想を取り入れる

- データ同化の扱う問題で、観測データの量が、推定したい変数  $x$  の次元よりも多いという状況は、滅多にない。
- また、データの量が多かったとしても、行列  $H$  の構造によっては、いい推定にはならない場合がある。
- データの情報が十分ではない場合、 $x$  は大体このあたりだろうと事前に予想をつけておき、その予想を第一推定値を  $\bar{x}_b$  として、

$$\|y - Hx\|^2 + \xi^2 \|x - \bar{x}_b\|^2 \rightarrow \text{minimum}$$

となるように  $\hat{x}$  を求めるという方法が有効な場合がある。

- $\bar{x}_b$  には、例えば前のステップからシミュレーションを走らせた結果を使ってもよいし、過去のデータの平均値のような経験的な値を使ってもよい。



# 拘束付き最小二乗法

$$\Psi_C = \|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2 + \xi^2 \|\mathbf{x} - \bar{\mathbf{x}}_b\|^2 = \sum_{i=1}^n \left( y_i - \sum_{j=1}^m H_{ij} x_j \right)^2 + \sum_{k=1}^m \xi^2 (x_k - x_{b,k})^2 \quad (19)$$

とおくと,

$$\frac{\partial \Psi_C}{\partial x_k} = -2 \sum_{i=1}^n H_{ik} \left( y_i - \sum_{j=1}^m H_{ij} x_j \right) + 2\xi^2 (x_k - x_{b,k}) = 0$$

なので, これをまとめて書くと,

$$\begin{aligned} -\mathbf{H}^\top \mathbf{y} + \mathbf{H}^\top \mathbf{H} \mathbf{x} + \xi^2 (\mathbf{x} - \bar{\mathbf{x}}_b) &= -\mathbf{H}^\top \mathbf{y} + \mathbf{H}^\top \mathbf{H} \bar{\mathbf{x}}_b + \mathbf{H}^\top \mathbf{H} (\mathbf{x} - \bar{\mathbf{x}}_b) + \xi^2 (\mathbf{x} - \bar{\mathbf{x}}_b) \\ &= -\mathbf{H}^\top (\mathbf{y} - \mathbf{H} \bar{\mathbf{x}}_b) + (\mathbf{H}^\top \mathbf{H} + \xi^2 \mathbf{I}) (\mathbf{x} - \bar{\mathbf{x}}_b) = 0. \end{aligned}$$

したがって, 以下のようなになる.

$$\hat{\mathbf{x}} = \bar{\mathbf{x}}_b + (\mathbf{H}^\top \mathbf{H} + \xi^2 \mathbf{I}_n)^{-1} \mathbf{H}^\top (\mathbf{y} - \mathbf{H} \bar{\mathbf{x}}_b) \quad (20)$$

# 逆行列の存在について

今、行列  $H^T H + \xi^2 I_n$  が逆行列を持つものとして話を進めたが、 $\xi \neq 0$  であれば、必ず逆行列は存在する。

一般に、 $A$  を  $n$  次の半正定値対称行列、 $B$  を  $m$  次の正定値対称行列、 $H$  を  $m \times n$  行列としたとき、行列  $H^T A H + B$  は正則行列となる。

まず、 $A, B$  が対称行列であることから

$$(H^T A H + B)^T = H^T A H + B$$

となり、 $H^T A H + B$  は対称行列。また、 $A$  が半正定値対称行列で、任意の  $n$  次元ベクトル  $x$  に対して  $x^T A x \geq 0$  が成り立つので、任意の  $m$  次元ベクトル  $z$  に対して  $z^T H^T A H z \geq 0$ 。

$B$  が正定値対称行列なので、 $z$  が零ベクトルでなければ  $z^T (H^T A H + B) z > 0$  が成り立ち、 $H^T A H + B$  は正定値対称行列。したがって、正則である。

# 特異値分解による方法

次に、事前の予想  $\bar{x}_b$  を用いた推定を特異値分解を使って行ってみる。

そのためには、 $\{v_1, \dots, v_m\}$  を用いて  $x - \bar{x}_b$  を

$$x - \bar{x}_b = \sum_{i=1}^m \alpha'_i v_i, \quad (21)$$

$\{u_1, \dots, u_n\}$  を用いて  $y - H\bar{x}_b$  を

$$y - H\bar{x}_b = \sum_{i=1}^n \beta'_i u_i \quad (22)$$

のように分解した上で、

$$\Psi_C = \|y - Hx\|^2 + \xi^2 \|x - \bar{x}_b\|^2 \rightarrow \text{minimum}$$

とする  $x$  を求める。

# 特異値分解による方法

$$\begin{aligned}
 \Psi_C &= \|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2 + \xi^2 \|\mathbf{x} - \bar{\mathbf{x}}_b\|^2 \\
 &= \left\| \sum_{i=1}^n \beta'_i \mathbf{u}_i - \left( \sum_{i=1}^r \lambda_i \mathbf{u}_i \mathbf{v}_i^\top \right) \left( \sum_{i=1}^r \alpha'_i \mathbf{v}_i \right) \right\|^2 + \xi^2 \left\| \sum_{i=1}^m \alpha'_i \mathbf{v}_i \right\|^2 \\
 &= \left\| \sum_{i=1}^n \beta'_i \mathbf{u}_i - \sum_{i=1}^r \lambda_i \alpha'_i \mathbf{u}_i \right\|^2 + \xi^2 \left\| \sum_{i=1}^m \alpha'_i \mathbf{v}_i \right\|^2 \\
 &= \sum_{i=1}^r (\beta'_i - \lambda_i \alpha'_i)^2 + \sum_{i=r+1}^n \beta_i'^2 + \xi^2 \sum_{i=1}^m \alpha_i'^2
 \end{aligned} \tag{23}$$

$$\therefore \frac{\partial \Psi_C}{\partial \alpha'_i} = - \sum_{i=1}^r 2\lambda_i (\beta'_i - \lambda_i \alpha'_i) + \xi^2 \sum_{i=1}^m 2\alpha'_i = 0 \tag{24}$$

したがって、 $\Psi_C$  が最小になる  $\alpha'_i$  は以下を満たす:

$$\lambda_i \beta'_i = \lambda_i^2 \alpha'_i + \xi^2 \alpha'_i \quad (i \leq r), \quad \alpha'_i = 0 \quad (i > r) \tag{25}$$

# 特異値分解による方法

したがって,

$$\alpha'_i = \frac{\lambda_i \beta'_i}{\lambda_i^2 + \xi^2} \quad (i \leq r), \quad \alpha'_i = 0 \quad (i > r). \quad (26)$$

$\lambda_{r+1} = \cdots = \lambda_m = 0$  とおくと,  $i > r$  の場合も含めて,

$$\alpha'_i = \frac{\lambda_i \beta'_i}{\lambda_i^2 + \xi^2} \quad (27)$$

と書け,  $\Psi_C$  を最小とする  $\hat{x}$  は

$$\hat{x} = \bar{x}_b + \sum_{i=1}^m \frac{\lambda_i \beta'_i}{\lambda_i^2 + \xi^2} v_i. \quad (28)$$

# 特異値分解による方法

$$\hat{\boldsymbol{x}} = \bar{\boldsymbol{x}}_b + \sum_{i=1}^m \frac{\lambda_i \beta'_i}{\lambda_i^2 + \xi^2} \boldsymbol{v}_i$$

において,


- $\lambda_i^2 \gg \xi^2$  となる項は, 最小二乗解とほぼ同じとなり,
- $\lambda_i^2 \ll \xi^2$  となる項は, ほぼ 0 になる.

したがって, 拘束条件を付けた場合は,  $\lambda_i^2$  が小さい項が無視され, 解を安定化させる効果が得られる.

# ベイズの定理

予想をつけておいた上で、実データを参照して修正するという考え方は、ベイズの定理を用いて表現することもできる。

$$p(\boldsymbol{x}|\boldsymbol{y}) = \frac{p(\boldsymbol{y}|\boldsymbol{x})p(\boldsymbol{x})}{\int p(\boldsymbol{y}|\boldsymbol{x})p(\boldsymbol{x}) d\boldsymbol{x}}. \quad (29)$$



# ベイズの定理

- ある事象  $A$  が起こったとき、考えられる原因を  $B_1, B_2, \dots, B_n$  とする.
- 原因  $B_j$  が与えられたとき、結果が  $A$  となる確率  $P(A|B_i)$  はわかっているとする.
- $B_1, \dots, B_n$  は互いに排反 (同時には起こり得ない) で、かつ  $B_1, \dots, B_n$  で考えられるすべての場合が考慮されているとする.
- このとき、原因が  $B_i$  である確率は

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{P(A)} = \frac{P(A|B_i)P(B_i)}{\sum_j P(A|B_j)P(B_j)}. \quad (30)$$

(事前情報  $p(B_j)$  が与えられれば、観測  $A$  から原因を推定可能.)

- 連続量の場合に以下の形になる.


$$p(\mathbf{x}|\mathbf{y}) = \frac{p(\mathbf{y}|\mathbf{x})p(\mathbf{x})}{p(\mathbf{y})} = \frac{p(\mathbf{y}|\mathbf{x})p(\mathbf{x})}{\int p(\mathbf{y}|\mathbf{x})p(\mathbf{x}) d\mathbf{x}} \quad (31)$$



# ベイズの定理

ベイズの定理  $p(x|y) = \frac{p(y|x)p(x)}{\int p(y|x)p(x) dx}$  において,

- $p(x)$  は,  $x$  に関する事前の予想を表す. (事前分布と呼ぶ).
- $p(y|x)$  は,  $x$  がこの値だったら, このくらいの確率で  $y$  が観測されるということを表す. (また, 観測への  $x$  の当てはまり具合を表している面もある.)
- $p(x|y)$  は, 与えられた観測  $y$  の下で  $x$  を推定したもの. (事後分布と呼ぶ.)



# ベイズの定理に基づく推定

ここでは、ベイズの定理

$$p(\mathbf{x}|\mathbf{y}) = \frac{p(\mathbf{y}|\mathbf{x})p(\mathbf{x})}{\int p(\mathbf{y}|\mathbf{x})p(\mathbf{x}) d\mathbf{x}} \quad (32)$$

において、 $p(\mathbf{x})$ ,  $p(\mathbf{y}|\mathbf{x})$  がガウス分布に従うと仮定して、

$$p(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^m |\mathbf{P}_b|}} \exp \left( -\frac{1}{2} (\mathbf{x} - \bar{\mathbf{x}}_b)^\top \mathbf{P}_b^{-1} (\mathbf{x} - \bar{\mathbf{x}}_b) \right), \quad (33)$$

$$p(\mathbf{y}|\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^n |\mathbf{R}|}} \exp \left( -\frac{1}{2} (\mathbf{y} - \mathbf{H}\mathbf{x})^\top \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H}\mathbf{x}) \right), \quad (34)$$

とする．上の式に代入すると、以下が満たされることが分かる：

$$p(\mathbf{x}|\mathbf{y}) \propto \exp \left( -\frac{1}{2} (\mathbf{x} - \bar{\mathbf{x}}_b)^\top \mathbf{P}_b^{-1} (\mathbf{x} - \bar{\mathbf{x}}_b) - \frac{1}{2} (\mathbf{y} - \mathbf{H}\mathbf{x})^\top \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H}\mathbf{x}) \right). \quad (35)$$

# ベイズの定理に基づく推定

$x$  を推定するには、事後確率

$$p(x|y) \propto \exp \left( -\frac{1}{2}(x - \bar{x}_b)^T \mathbf{P}_b^{-1}(x - \bar{x}_b) - \frac{1}{2}(y - \mathbf{H}x)^T \mathbf{R}^{-1}(y - \mathbf{H}x) \right)$$

の平均，あるいは事後確率を最大化する  $x$  を求めるのが，よく使われる手段。  
(ガウス分布を仮定するとどちらでも同じ結果になる。)

$p(x|y)$  の  $\exp$  の指数部分を  $-\Psi_B/2$  とおくと，

$$\Psi_B = (x - \bar{x}_b)^T \mathbf{P}_b^{-1}(x - \bar{x}_b) + (y - \mathbf{H}x)^T \mathbf{R}^{-1}(y - \mathbf{H}x) \quad (36)$$

を最小にする  $x$  が， $p(x|y)$  を最大にする  $x$  となる。

以下，しばらくの間， $\mathbf{P}_b$ ， $\mathbf{R}$  は正定値行列 (0 固有値を持たない) とする。

\* 分散共分散行列が 0 固有値を持つ場合，逆行列が存在しなくなって都合が悪い。

# ベイズの定理に基づく推定

拘束付き最小二乗法の目的関数

$$\Psi_C = \|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2 + \xi^2 \|\mathbf{x} - \bar{\mathbf{x}}_b\|^2$$

は、ベイズの定理から得た

$$\Psi_B = (\mathbf{x} - \bar{\mathbf{x}}_b)^\top \mathbf{P}_b^{-1} (\mathbf{x} - \bar{\mathbf{x}}_b) + (\mathbf{y} - \mathbf{H}\mathbf{x})^\top \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H}\mathbf{x})$$

において、 $\mathbf{P}_b = \xi^2 \mathbf{I}$  かつ  $\mathbf{R} = \mathbf{I}$  とした場合と等価。

$\Psi_B$  は  $\Psi_C$  の一般になっており、 $\Psi_B$  の方が予測の確度、観測の確度の情報を柔軟に取り入れられるのが利点。

# ベイズの定理に基づく推定

例えば、 $x$  の  $i$  番目の要素  $x_i$  に関する予想の不確かさの幅を  $\zeta_i$ 、 $y$  の  $i$  番目の要素  $y_i$  の不確かさの幅を  $\sigma_i$  で表し、 $x$ 、 $y$  の異なる要素の間に事前に想定される相関がないものとするば、

$$\mathbf{P}_b = \begin{pmatrix} \zeta_1^2 & & & \mathbf{O} \\ & \zeta_2^2 & & \\ & & \ddots & \\ \mathbf{O} & & & \zeta_m^2 \end{pmatrix}, \quad \mathbf{R} = \begin{pmatrix} \sigma_1^2 & & & \mathbf{O} \\ & \sigma_2^2 & & \\ & & \ddots & \\ \mathbf{O} & & & \sigma_m^2 \end{pmatrix} \quad (37)$$

のように  $\mathbf{P}_b$ 、 $\mathbf{R}$  はそれぞれ対角行列で書ける。このとき  $\Psi_B$  は

$$\Psi_B = \sum_{i=1}^m \zeta_i^{-2} (x_i - \bar{x}_{b,i})^2 + \sum_{i=1}^n \sigma_i^{-2} \left( y_i - \sum_{j=1}^m H_{ij} x_{b,j} \right)^2. \quad (38)$$

$x$ 、 $y$  の各要素が不確かさの逆数で重みづけされており、不確かさの小さい (信用できる) 情報ほど大きな重みがついている。したがって、 $\Psi_B$  を最小化すると、信用できる情報をより重視した推定値が得られる。

# ベイズの定理に基づく推定

$$\Psi_B = (x - \bar{x}_b)^T \mathbf{P}_b^{-1} (x - \bar{x}_b) + (y - \mathbf{H}x)^T \mathbf{R}^{-1} (y - \mathbf{H}x)$$

は、以下の形に変形できる:

$$\Psi_B = (x - \hat{x})^T (\mathbf{P}_b^{-1} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H}) (x - \hat{x}) + A. \quad (39)$$

但し、

- $A$  は  $x$  によらない定数,
- $\hat{x}$  は,

$$(\mathbf{P}_b^{-1} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H}) \hat{x} = \mathbf{P}_b^{-1} \bar{x}_b + \mathbf{H}^T \mathbf{R}^{-1} y$$

を満たすベクトル.

# ベイズの定理に基づく推定

$\hat{x}$  については,

$$\begin{aligned}(\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H}) \hat{x} &= \mathbf{P}_b^{-1} \bar{x}_b + \mathbf{H}^\top \mathbf{R}^{-1} y \\ &= (\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H}) \bar{x}_b + \mathbf{H}^\top \mathbf{R}^{-1} (y - \mathbf{H} \bar{x}_b)\end{aligned}\tag{40}$$

より, 以下のように求められる:

$$\hat{x} = \bar{x}_b + (\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H})^{-1} \mathbf{H}^\top \mathbf{R}^{-1} (y - \mathbf{H} \bar{x}_b).\tag{41}$$

但し, 分散共分散行列  $\mathbf{P}_b$ ,  $\mathbf{R}$  を正定値対称行列としたので,

- $\mathbf{P}_b^{-1}$ ,  $\mathbf{R}^{-1}$  も正定値対称行列で,
- $\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H}$  も正定値対称行列

となり,  $\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H}$  が逆行列を持つことに注意.

# ベイズの定理に基づく推定

$$\begin{aligned}
 -\frac{\Psi_B}{2} &= -\frac{1}{2}(\mathbf{x} - \bar{\mathbf{x}}_b)^\top \mathbf{P}_b^{-1}(\mathbf{x} - \bar{\mathbf{x}}_b) - \frac{1}{2}(\mathbf{y} - \mathbf{H}\mathbf{x})^\top \mathbf{R}^{-1}(\mathbf{y} - \mathbf{H}\mathbf{x}) \\
 &= -\frac{1}{2}(\mathbf{x} - \hat{\mathbf{x}})^\top (\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H})(\mathbf{x} - \hat{\mathbf{x}}) - A.
 \end{aligned}$$

から、 $\hat{\mathbf{P}} = (\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H})^{-1}$  とおくと、事後分布  $p(\mathbf{x}|\mathbf{y})$  は、

$$p(\mathbf{x}|\mathbf{y}) \propto \exp\left(-\frac{1}{2}(\mathbf{x} - \hat{\mathbf{x}})^\top \hat{\mathbf{P}}^{-1}(\mathbf{x} - \hat{\mathbf{x}})\right) \quad (42)$$

を満たすことがわかる。

したがって、 $p(\mathbf{x}|\mathbf{y})$  は、平均ベクトル  $\hat{\mathbf{x}}$ 、分散共分散行列  $\hat{\mathbf{P}}$  のガウス分布になる。



# ベイズの定理に基づく推定

分散共分散行列については,

$$\hat{\mathbf{P}} = (\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H})^{-1} = \mathbf{P}_b - \mathbf{P}_b \mathbf{H}^\top (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} \mathbf{H} \mathbf{P}_b \quad (43)$$

とも変形できる．このことは,

$$\begin{aligned} & (\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H}) [\mathbf{P}_b - \mathbf{P}_b \mathbf{H}^\top (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} \mathbf{H} \mathbf{P}_b] \\ &= \mathbf{I} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H} \mathbf{P}_b - \mathbf{H}^\top (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} \mathbf{H} \mathbf{P}_b \\ &\quad - \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H} \mathbf{P}_b \mathbf{H}^\top (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} \mathbf{H} \mathbf{P}_b \\ &= \mathbf{I} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H} \mathbf{P}_b - \mathbf{H}^\top \mathbf{R}^{-1} (\mathbf{R} + \mathbf{H} \mathbf{P}_b \mathbf{H}^\top) (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} \mathbf{H} \mathbf{P}_b = \mathbf{I} \end{aligned} \quad (44)$$

となることから確認できる．

# ベイズの定理に基づく推定

また、平均ベクトルの式，

$$\hat{x} = \bar{x}_b + (\mathbf{P}_b^{-1} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H})^{-1} \mathbf{H}^T \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H} \bar{x}_b). \quad (45)$$

は，

$$(\mathbf{P}_b^{-1} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H})^{-1} = \mathbf{P}_b - \mathbf{P}_b \mathbf{H}^T (\mathbf{H} \mathbf{P}_b \mathbf{H}^T + \mathbf{R})^{-1} \mathbf{H} \mathbf{P}_b \quad (46)$$

を代入すると，以下のように変形できる：

$$\begin{aligned} \hat{x} &= \bar{x}_b + [\mathbf{P}_b - \mathbf{P}_b \mathbf{H}^T (\mathbf{H} \mathbf{P}_b \mathbf{H}^T + \mathbf{R})^{-1} \mathbf{H} \mathbf{P}_b] \mathbf{H}^T \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H} \bar{x}_b) \\ &= \bar{x}_b + \mathbf{P}_b \mathbf{H}^T [\mathbf{I} - (\mathbf{H} \mathbf{P}_b \mathbf{H}^T + \mathbf{R})^{-1} \mathbf{H} \mathbf{P}_b \mathbf{H}^T] \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H} \bar{x}_b) \\ &= \bar{x}_b + \mathbf{P}_b \mathbf{H}^T (\mathbf{H} \mathbf{P}_b \mathbf{H}^T + \mathbf{R})^{-1} [(\mathbf{H} \mathbf{P}_b \mathbf{H}^T + \mathbf{R}) - \mathbf{H} \mathbf{P}_b \mathbf{H}^T] \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H} \bar{x}_b) \\ &= \bar{x}_b + \mathbf{P}_b \mathbf{H}^T (\mathbf{H} \mathbf{P}_b \mathbf{H}^T + \mathbf{R})^{-1} (\mathbf{y} - \mathbf{H} \bar{x}_b). \end{aligned}$$

- $\dim x > \dim y$  の場合には，こちらの方が便利である．
- 後で出てくるカルマンフィルタでもこの式を使う．

# ベイズの定理に基づく推定 (まとめ)

$p(\mathbf{x}) = \mathcal{N}(\bar{\mathbf{x}}_b, \mathbf{P}_b)$ ,  $p(\mathbf{y}|\mathbf{x}) = \mathcal{N}(\mathbf{H}\mathbf{x}, \mathbf{R})$  のとき, 事後分布  $p(\mathbf{x}|\mathbf{y})$  もガウス分布となり, 平均ベクトル, 分散共分散行列は以下ようになる.

■ 平均ベクトル:

$$\begin{aligned}\hat{\mathbf{x}} &= \bar{\mathbf{x}}_b + (\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H})^{-1} \mathbf{H}^\top \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H} \bar{\mathbf{x}}_b) \\ &= \bar{\mathbf{x}}_b + \mathbf{P}_b \mathbf{H}^\top (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} (\mathbf{y} - \mathbf{H} \bar{\mathbf{x}}_b),\end{aligned}\tag{47}$$

■ 分散共分散行列:

$$\begin{aligned}\hat{\mathbf{P}} &= (\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H})^{-1} \\ &= \mathbf{P}_b - \mathbf{P}_b \mathbf{H}^\top (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} \mathbf{H} \mathbf{P}_b\end{aligned}\tag{48}$$

# 最適内挿法

## ■ ベイズ推定の式

$$\begin{aligned}\hat{x} &= \bar{x}_b + \mathbf{P}_b \mathbf{H}^\top (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} (\mathbf{y} - \mathbf{H} \bar{x}_b), \\ \hat{\mathbf{P}} &= \mathbf{P}_b - \mathbf{P}_b \mathbf{H}^\top (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} \mathbf{H} \mathbf{P}_b\end{aligned}$$

は、データ同化では最適内挿法と呼ばれる手法に相当する。

- 実際に使用する際には、 $\mathbf{P}_b$  や  $\mathbf{R}$  の設計が問題になる。
- $\mathbf{P}_b$  については、グリッド点間の距離の関数

$$\sigma^2 \exp \left[ -\frac{\|z_i - z_j\|^2}{2\ell^2} \right] \quad (49)$$

のようなものを使うこともある。

# 補足

なお、途中で使った、

$$(\mathbf{P}^{-1} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H})^{-1} \mathbf{H}^T \mathbf{R}^{-1} = \mathbf{P} \mathbf{H}^T (\mathbf{H} \mathbf{P} \mathbf{H}^T + \mathbf{R})^{-1}, \quad (50a)$$

$$(\mathbf{P}^{-1} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H})^{-1} = \mathbf{P} - \mathbf{P} \mathbf{H}^T (\mathbf{H} \mathbf{P} \mathbf{H}^T + \mathbf{R})^{-1} \mathbf{H} \mathbf{P} \quad (50b)$$

という公式は、逆行列補題，Sherman-Morrison-Woodbury 公式などと呼ばれ，このあと，何度か出てくる。

## $P_b$ が 0 固有値を持つ場合

$x$  の事前分布の分散共分散行列  $P_b$  が 0 固有値を持つ場合,  $P_b = \check{U}\check{\Lambda}\check{U}^T$  のように固有値分解し,

$$x = \bar{x}_b + \check{U}z \quad (51)$$

とすれば, ガウス分布  $\mathcal{N}(0, \check{\Lambda})$  に従う確率変数  $z$  を使って  $x$  を表現することができる.

(ここでは,  $\check{\Lambda}$  が正定値 (正則) になるように 0 の固有値に対応する成分を削った,

$$P_b = \check{U}\check{\Lambda}\check{U}^T = (\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r) \begin{pmatrix} \lambda_1 & & \mathbf{O} \\ & \ddots & \\ \mathbf{O} & & \lambda_r \end{pmatrix} (\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r)^T \quad (52)$$

の方を使う.)

## $P_b$ が 0 固有値を持つ場合

ガウス分布  $\mathcal{N}(0, \check{\Lambda})$  に従う確率変数  $z$  を使い,  $x$  を

$$x = \bar{x}_b + \check{U}z \quad (53)$$

のように表現したとき,

$$p(z) = \frac{1}{\sqrt{(2\pi)^r}} \exp\left(-\frac{1}{2}z^\top \check{\Lambda}^{-1}z\right), \quad (54)$$

$$p(y|z) = \frac{1}{\sqrt{(2\pi)^n |\mathbf{R}|}} \exp\left(-\frac{1}{2}(y - \mathbf{H}\bar{x}_b - \mathbf{H}\check{U}z)^\top \mathbf{R}^{-1}(y - \mathbf{H}\bar{x}_b - \mathbf{H}\check{U}z)\right), \quad (55)$$

の下で,  $z$  の事後分布を求めればよい.

\*  $\Lambda$  は正則なので,  $z$  の確率密度関数が定義できる.

## $P_b$ が 0 固有値を持つ場合

$z$  の分散共分散行列  $\check{\Lambda}$  は正定値なので,  $z$  の事後分布の平均は, 先程の式から直ちに求まる.

$$\hat{z} = (\check{\Lambda}^{-1} + \check{\mathbf{U}}^T \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H} \check{\mathbf{U}})^{-1} \check{\mathbf{U}}^T \mathbf{H}^T \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H} \bar{x}_b). \quad (56)$$

両辺に左から  $\check{\mathbf{U}}$  を掛けた上で変形すると,

$$\begin{aligned} \check{\mathbf{U}} \hat{z} &= \check{\mathbf{U}} (\check{\Lambda}^{-1} + \check{\mathbf{U}}^T \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H} \check{\mathbf{U}})^{-1} \check{\mathbf{U}}^T \mathbf{H}^T \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H} \bar{x}_b) \\ &= \check{\mathbf{U}} \check{\Lambda} \check{\mathbf{U}}^T \mathbf{H}^T (\mathbf{H} \check{\mathbf{U}} \check{\Lambda} \check{\mathbf{U}}^T \mathbf{H}^T + \mathbf{R})^{-1} (\mathbf{y} - \mathbf{H} \bar{x}_b) \\ &= \mathbf{P}_b \mathbf{H}^T (\mathbf{H} \mathbf{P}_b \mathbf{H}^T + \mathbf{R})^{-1} (\mathbf{y} - \mathbf{H} \bar{x}_b) \end{aligned} \quad (57)$$

したがって,

$$\hat{x} = \bar{x}_b + \mathbf{P}_b \mathbf{H}^T (\mathbf{H} \mathbf{P}_b \mathbf{H}^T + \mathbf{R})^{-1} (\mathbf{y} - \mathbf{H} \bar{x}_b). \quad (58)$$



# $P_b$ が 0 固有値を持つ場合

$z$  の事後分布の分散共分散行列も、先程の式から

$$\hat{P}_z = (\check{\Lambda}^{-1} - \check{U}^T H^T R^{-1} H \check{U})^{-1} \quad (59)$$

となるので、両辺の両側から  $\check{U}$  を掛けた上で変形すると、

$$\begin{aligned} \hat{P} &= \check{U} \hat{P}_z \check{U}^T \\ &= \check{U} (\check{\Lambda}^{-1} - \check{U}^T H^T R^{-1} H \check{U})^{-1} \check{U}^T \\ &= \check{U} [\check{\Lambda} - \check{\Lambda} \check{U}^T H^T (H \check{U} \check{\Lambda} \check{U}^T H^T + R)^{-1} H \check{U} \check{\Lambda}] \check{U}^T \\ &= \check{U} \check{\Lambda} \check{U}^T - \check{U} \check{\Lambda} \check{U}^T H^T (H \check{U} \check{\Lambda} \check{U}^T H^T + R)^{-1} H \check{U} \check{\Lambda} \check{U}^T \\ &= P_b - P_b H^T (H P_b H^T + R)^{-1} H P_b \end{aligned} \quad (60)$$

つまり、正則の場合の平均ベクトル、分散共分散行列の式を非正則な場合に適用しても問題ない。

# まとめ

- 多変量の問題における最小二乗法とその拡張について述べた。
- データの情報が十分ではない場合、単純な最小二乗法ではうまく行かないため、解に関して事前に予想を付け加え、その予想に基づいて推定を行うという方法がある。
- 事前の予想を付加する方法は、ベイズ推定の枠組みに一般化できる。今回は、正規分布を仮定できる場合に限って説明したが、正規分布以外の事前分布、尤度を考えることも可能である。但し、正規分布を仮定しない場合、解析的に事後分布を得られるとは限らない。