

## 2 最小二乗法とベイズ推定

### 最小二乗法

データ同化でやりたいことは,

$$\mathbf{x}_k = \mathbf{f}_k(\mathbf{x}_{k-1}) + \mathbf{v}_k,$$

$$\mathbf{y}_k = \mathbf{H}_k \mathbf{x}_k + \mathbf{w}_k$$

の2種類の関係式が与えられ, 更に各時刻の観測データ  $\mathbf{y}_k$  が与えられたという条件の下で, 各時刻の  $\mathbf{x}_k$  を推定することであった. しかし, まずはシステムモデル  $\mathbf{x}_k = \mathbf{f}_k(\mathbf{x}_{k-1}) + \mathbf{v}_k$  は無視し, 各時間ステップで, 観測  $\mathbf{y}$  が与えられた下で  $\mathbf{y}_k = \mathbf{H}_k \mathbf{x}_k + \mathbf{w}_k$  という観測モデルに基づいて  $\mathbf{x}$  を推定するという問題を考える.

まずは,  $\mathbf{y} = \mathbf{H}\mathbf{x} + \mathbf{w}$  において,  $\|\mathbf{w}\|^2$  をなるべく小さくするという方針を考える. それはつまり,

$$\|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2$$

を最小化する問題で, 所謂最小二乗法である. データ数  $n$  が未知変数の数  $m$  よりも多い場合 ( $n > m$ ) には, 「基本的に」これで  $\mathbf{x}$  が決まる.

$$\Psi_L = \|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2 = \sum_{i=1}^n \left( y_i - \sum_{j=1}^m H_{ij} x_j \right)^2 \quad (1)$$

とおくと,

$$\frac{\partial \Psi_L}{\partial x_k} = -2 \sum_{i=1}^n H_{ik} \left( y_i - \sum_{j=1}^m H_{ij} x_j \right) \quad (2)$$

なので,

$$-\mathbf{H}^T \mathbf{y} + \mathbf{H}^T \mathbf{H} \mathbf{x} = 0. \quad (3)$$

したがって,  $\mathbf{H}^T \mathbf{H}$  が正則 (逆行列を持つ) なら

$$\hat{\mathbf{x}} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y}. \quad (4)$$

例として, 変数  $z$  の列  $\{z_1, z_2, \dots, z_n\}$  に対して, 変数  $y$  に関するデータ  $\{y_1, y_2, \dots, y_n\}$  が得られているとき,  $y$  を

$$y = a_0 + a_1 z + \varepsilon \quad (5)$$

という式で説明することを考える.

$$\mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}, \quad \mathbf{H} = \begin{pmatrix} 1 & z_1 \\ \vdots & \vdots \\ 1 & z_n \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} a_0 \\ a_1 \end{pmatrix}, \quad \mathbf{w} = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

とおくと, 先程の  $\mathbf{y} = \mathbf{H}\mathbf{x} + \mathbf{w}$  の形になる. これに対して, 式 (4) の推定式を適用する.

$\bar{z} = \sum z_i/n, \bar{y} = \sum y_i/n$  として,

$$\mathbf{H}^T \mathbf{H} = \begin{pmatrix} n & \sum z_i \\ \sum z_i & \sum z_i^2 \end{pmatrix} = \begin{pmatrix} n & n\bar{z} \\ n\bar{z} & \sum z_i^2 \end{pmatrix}, \quad \mathbf{H}^T \mathbf{y} = \begin{pmatrix} \sum y_i \\ \sum z_i y_i \end{pmatrix} = \begin{pmatrix} n\bar{y} \\ \sum z_i y_i \end{pmatrix}.$$

$$\begin{aligned} \hat{\mathbf{x}} &= (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y} = \frac{1}{n \sum z_i^2 - n^2 \bar{z}^2} \begin{pmatrix} \sum z_i^2 & -n\bar{z} \\ -n\bar{z} & n \end{pmatrix} \begin{pmatrix} n\bar{y} \\ \sum z_i y_i \end{pmatrix} \\ &= \frac{1}{n^2 C_{zz}} \begin{pmatrix} n\bar{y} \sum z_i^2 - n\bar{z} \sum z_i y_i \\ n \sum z_i y_i - n^2 \bar{z} \bar{y} \end{pmatrix} = \frac{1}{n^2 C_{zz}} \begin{pmatrix} n\bar{y} \sum z_i^2 - n^2 \bar{z}^2 \bar{y} - n\bar{z}(\sum z_i y_i - n\bar{z} \bar{y}) \\ n^2 C_{zy} \end{pmatrix} \\ &= \frac{1}{C_{zz}} \begin{pmatrix} \bar{y} C_{zz} - \bar{z} C_{zy} \\ C_{zy} \end{pmatrix} = \begin{pmatrix} \bar{y} - \bar{z}(C_{zy}/C_{zz}) \\ C_{zy}/C_{zz} \end{pmatrix} \end{aligned} \quad (6)$$

但し,

$$C_{zz} = \frac{1}{n} \sum z_i^2 - \bar{z}^2, \quad C_{zy} = \frac{1}{n} \sum z_i y_i - \bar{z} \bar{y}.$$

## 特異値分解と最小二乗法

$\Psi_L = \|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2$  を最小化する  $\mathbf{x}$  は, 特異値分解を使って得ることもできる. まずは,  $\mathbf{H}$  を以下のように特異値分解する:

$$\mathbf{H} = \check{\mathbf{U}} \check{\mathbf{\Lambda}} \check{\mathbf{V}}^T = \sum_{i=1}^r \lambda_i \mathbf{u}_i \mathbf{v}_i^T. \quad (7)$$

また,  $\{\mathbf{v}_1, \dots, \mathbf{v}_m\}, \{\mathbf{u}_1, \dots, \mathbf{u}_n\}$  はそれぞれ  $\mathbf{x}, \mathbf{y}$  が定義されるベクトル空間の正規直交基底なので,

$$\mathbf{x} = \sum_{i=1}^m \alpha_i \mathbf{v}_i, \quad \mathbf{y} = \sum_{i=1}^n \beta_i \mathbf{u}_i \quad (8)$$

と書くことができる. 但し, 各  $i$  に対して  $\alpha_i = \mathbf{v}_i^T \mathbf{x}, \beta_i = \mathbf{u}_i^T \mathbf{y}$ . これを使って,  $\Psi_L = \|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2$  を計算する. 計算してみると,

$$\begin{aligned} \Psi_L = \|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2 &= \left\| \sum_{i=1}^n \beta_i \mathbf{u}_i - \left( \sum_{i=1}^r \lambda_i \mathbf{u}_i \mathbf{v}_i^T \right) \left( \sum_{i=1}^m \alpha_i \mathbf{v}_i \right) \right\|^2 \\ &= \left\| \sum_{i=1}^n \beta_i \mathbf{u}_i - \sum_{i=1}^r \lambda_i \alpha_i \mathbf{u}_i \right\|^2 = \left\| \sum_{i=1}^r (\beta_i - \lambda_i \alpha_i) \mathbf{u}_i + \sum_{i=r+1}^n \beta_i \mathbf{u}_i \right\|^2 \\ &= \sum_{i=1}^r (\beta_i - \lambda_i \alpha_i)^2 + \sum_{i=r+1}^n \beta_i^2. \end{aligned} \quad (9)$$

$r = m (= \dim \mathbf{x})$  の場合,  $\alpha_i = \beta_i / \lambda_i$  ( $1 \leq i \leq r$ ) とすればよく,

$$\hat{\mathbf{x}} = \operatorname{argmin}_{\mathbf{x}} \|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2 = \sum_{i=1}^m \frac{\beta_i}{\lambda_i} \mathbf{v}_i. \quad (10)$$

先に得られた推定値  $\hat{\mathbf{x}} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y}$  は,  $r = m \leq n$  のとき

$$(\mathbf{H}^T \mathbf{H})^{-1} = (\mathbf{V} \mathbf{\Lambda} \mathbf{U}^T \mathbf{U} \mathbf{\Lambda} \mathbf{V}^T)^{-1} = (\mathbf{V} \mathbf{\Lambda}^2 \mathbf{V}^T)^{-1} = (\mathbf{V} \mathbf{\Lambda}^{-2} \mathbf{V}^T) = \sum_{i=1}^m \frac{1}{\lambda_i^2} \mathbf{v}_i \mathbf{v}_i^T \quad (11)$$

となり,

$$\mathbf{H}^T \mathbf{y} = \left( \sum_{i=1}^m \lambda_i \mathbf{v}_i \mathbf{u}_i^T \right) \left( \sum_{j=1}^m \beta_j \mathbf{u}_j \right) = \sum_{i=1}^m \lambda_i \beta_i \mathbf{v}_i \quad (12)$$

となることから,

$$(\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y} = \left( \sum_{i=1}^m \frac{1}{\lambda_i^2} \mathbf{v}_i \mathbf{v}_i^T \right) \left( \sum_{i=1}^m \lambda_i \beta_i \mathbf{v}_i \right) = \sum_{i=1}^m \frac{\beta_i}{\lambda_i} \mathbf{v}_i. \quad (13)$$

つまり, 特異値分解で求めた式と等価であることが分かる. なお,  $\mathbf{H}^T \mathbf{H}$  が逆行列を持つという条件は,  $r = m$  という条件と対応している.

$$\hat{\mathbf{x}} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y}. \quad (14)$$

の  $(\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T$  の部分は,  $\mathbf{H}$  のムーア・ペンローズ一般逆行列になっている. 実際,  $\mathbf{H}$  の特異値分解を

$$\mathbf{H} = \mathbf{\check{U}} \mathbf{\check{\Lambda}} \mathbf{\check{V}}^T$$

として, 計算すると,

$$\begin{aligned} (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T &= (\mathbf{\check{V}} \mathbf{\check{\Lambda}} \mathbf{\check{U}}^T \mathbf{\check{U}} \mathbf{\check{\Lambda}} \mathbf{\check{V}}^T)^{-1} \mathbf{\check{V}} \mathbf{\check{\Lambda}} \mathbf{\check{U}}^T = (\mathbf{\check{V}} \mathbf{\check{\Lambda}}^2 \mathbf{\check{V}}^T)^{-1} \mathbf{\check{U}} \mathbf{\check{\Lambda}} \mathbf{\check{V}}^T \\ &= \mathbf{\check{V}} \mathbf{\check{\Lambda}}^{-2} \mathbf{\check{V}}^T \mathbf{\check{V}} \mathbf{\check{\Lambda}} \mathbf{\check{U}}^T = \mathbf{\check{V}} \mathbf{\check{\Lambda}}^{-2} \mathbf{\check{\Lambda}} \mathbf{\check{U}}^T = \mathbf{\check{V}} \mathbf{\check{\Lambda}}^{-1} \mathbf{\check{U}}^T \end{aligned} \quad (15)$$

特異値分解から得られた結果

$$\hat{\mathbf{x}} = \sum_{i=1}^r \frac{\beta_i}{\lambda_i} \mathbf{v}_i \quad (16)$$

より,  $\lambda_i$  が小さい場合,  $\mathbf{x}$  の推定値は  $\beta_i$  に大きく影響されることも分かる.  $\beta_i$  に誤差がある場合, その誤差の  $\hat{\mathbf{x}}$  への影響が大きく増幅されるため, 安定した解が得られない.  $\hat{\mathbf{x}}$  を安定させるため,

$$\hat{\mathbf{x}} = \sum_{i=1}^l \frac{\beta_i}{\lambda_i} \mathbf{v}_i$$

$$(\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_l > \varepsilon \geq \lambda_{l+1} \geq \cdots \lambda_r > 0),$$

のように特異値の小さい成分を落とす場合もある.

$r < m \leq n$  の場合,  $\alpha_{r+1} \dots \alpha_m$  は  $\|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2$  に影響せず,

$$\hat{\mathbf{x}} = \sum_{i=1}^r \frac{\beta_i}{\lambda_i} \mathbf{v}_i + \sum_{i=r+1}^m \alpha_i \mathbf{v}_i.$$

の形であればよい. この式から以下のことが分かる:

- $\mathbf{H}$  を介した観測  $\mathbf{y}$  から,  $\mathbf{x}$  のうち  $\{\mathbf{v}_{r+1}, \dots, \mathbf{v}_m\}$  の成分に関する情報を得ることはできない.
- $\{\mathbf{v}_{r+1}, \dots, \mathbf{v}_m\}$  が決まらないため,  $\|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2$  が同じ値となる無数の解が存在する.

上の式で  $\alpha_i = 0$  ( $i > r$ ) と置いた

$$\hat{\mathbf{x}} = \sum_{i=1}^r \frac{\beta_i}{\lambda_i} \mathbf{v}_i \quad (17)$$

は,  $\|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2$  を最小化する  $\mathbf{x}$  の中でもノルムが最小となる解を与える. これは ノルム最小解と呼ばれる.

$r \leq n < m$  の場合もノルム最小解

$$\hat{\mathbf{x}} = \sum_{i=1}^r \frac{\beta_i}{\lambda_i} \mathbf{v}_i \quad (18)$$

を考えることができ,  $\|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2$  を最小化する  $\mathbf{x}$  の中でノルムが最小となるものを与える.

## 拘束付き最小二乗法

データ同化の扱う問題で、観測データの量が、推定したい変数  $\mathbf{x}$  の次元よりも多いという状況は、滅多にない。また、データの量が多かったとしても、行列  $\mathbf{H}$  の構造によっては、いい推定にはならない場合がある。データの情報が十分ではない場合、 $\mathbf{x}$  は大体このあたりだろうと事前に予想をつけておき、その予想を第一推定値を  $\bar{\mathbf{x}}_b$  とし、

$$\|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2 + \xi^2 \|\mathbf{x} - \bar{\mathbf{x}}_b\|^2 \rightarrow \text{minimum}$$

となるように  $\hat{\mathbf{x}}$  を求めるという方法が有効な場合がある。 $\bar{\mathbf{x}}_b$  には、例えば前のステップからシミュレーションを走らせた結果を使ってもよいし、過去のデータの平均値のような経験的な値を使ってもよい。

$$\Psi_C = \|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2 + \xi^2 \|\mathbf{x} - \bar{\mathbf{x}}_b\|^2 = \sum_{i=1}^n \left( y_i - \sum_{j=1}^m H_{ij} x_j \right)^2 + \sum_{k=1}^m \xi^2 (x_k - x_{b,k})^2 \quad (19)$$

とおくと、

$$\frac{\partial \Psi_C}{\partial x_k} = -2 \sum_{i=1}^n H_{ik} \left( y_i - \sum_{j=1}^m H_{ij} x_j \right) + 2\xi^2 (x_k - x_{b,k}) = 0$$

なので、

$$\begin{aligned} -\mathbf{H}^T \mathbf{y} + \mathbf{H}^T \mathbf{H} \mathbf{x} + \xi^2 (\mathbf{x} - \bar{\mathbf{x}}_b) &= -\mathbf{H}^T \mathbf{y} + \mathbf{H}^T \mathbf{H} \bar{\mathbf{x}}_b + \mathbf{H}^T \mathbf{H} (\mathbf{x} - \bar{\mathbf{x}}_b) + \xi^2 (\mathbf{x} - \bar{\mathbf{x}}_b) \\ &= -\mathbf{H}^T (\mathbf{y} - \mathbf{H} \bar{\mathbf{x}}_b) + (\mathbf{H}^T \mathbf{H} + \xi^2 \mathbf{I}) (\mathbf{x} - \bar{\mathbf{x}}_b) = 0. \end{aligned}$$

したがって、以下ようになる。

$$\hat{\mathbf{x}} = \bar{\mathbf{x}}_b + (\mathbf{H}^T \mathbf{H} + \xi^2 \mathbf{I}_n)^{-1} \mathbf{H}^T (\mathbf{y} - \mathbf{H} \bar{\mathbf{x}}_b) \quad (20)$$

なお、行列  $\mathbf{H}^T \mathbf{H} + \xi^2 \mathbf{I}_n$  が逆行列を持つものとして話を進めたが、 $\xi \neq 0$  であれば、必ず逆行列は存在する。一般に、 $\mathbf{A}$  を  $n$  次の半正定値対称行列、 $\mathbf{B}$  を  $m$  次の正定値対称行列、 $\mathbf{H}$  を  $m \times n$  行列としたとき、行列  $\mathbf{H}^T \mathbf{A} \mathbf{H} + \mathbf{B}$  は正則行列となる。

まず、 $\mathbf{A}, \mathbf{B}$  が対称行列であることから

$$(\mathbf{H}^T \mathbf{A} \mathbf{H} + \mathbf{B})^T = \mathbf{H}^T \mathbf{A} \mathbf{H} + \mathbf{B}$$

となり、 $\mathbf{H}^T \mathbf{A} \mathbf{H} + \mathbf{B}$  は対称行列。また、 $\mathbf{A}$  が半正定値対称行列で、任意の  $n$  次元ベクトル  $\mathbf{x}$  に対して  $\mathbf{x}^T \mathbf{A} \mathbf{x} \geq 0$  が成り立つので、任意の  $m$  次元ベクトル  $\mathbf{z}$  に対して  $\mathbf{z}^T \mathbf{H}^T \mathbf{A} \mathbf{H} \mathbf{z} \geq 0$ 。

$\mathbf{B}$  が正定値対称行列なので、 $\mathbf{z}$  が零ベクトルでなければ  $\mathbf{z}^T (\mathbf{H}^T \mathbf{A} \mathbf{H} + \mathbf{B}) \mathbf{z} > 0$  が成り立ち、 $\mathbf{H}^T \mathbf{A} \mathbf{H} + \mathbf{B}$  は正定値対称行列。正定値対称行列は正則なので、この行列は正則である。

## 特異値分解による方法

次に、事前の予想  $\bar{\mathbf{x}}_b$  を用いた推定を特異値分解を使って行ってみる。そのためには、 $\{\mathbf{v}_1, \dots, \mathbf{v}_m\}$  を用いて  $\mathbf{x} - \bar{\mathbf{x}}_b$  を

$$\mathbf{x} - \bar{\mathbf{x}}_b = \sum_{i=1}^m \alpha'_i \mathbf{v}_i, \quad (21)$$

$\{\mathbf{u}_1, \dots, \mathbf{u}_n\}$  を用いて  $\mathbf{y} - \mathbf{H}\bar{\mathbf{x}}_b$  を

$$\mathbf{y} - \mathbf{H}\bar{\mathbf{x}}_b = \sum_{i=1}^n \beta'_i \mathbf{u}_i \quad (22)$$

のように分解した上で,

$$\Psi_C = \|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2 + \xi^2 \|\mathbf{x} - \bar{\mathbf{x}}_b\|^2 \rightarrow \text{minimum}$$

の計算を行う.

$$\begin{aligned} \Psi_C &= \|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2 + \xi^2 \|\mathbf{x} - \bar{\mathbf{x}}_b\|^2 \\ &= \left\| \sum_{i=1}^n \beta'_i \mathbf{u}_i - \left( \sum_{i=1}^r \lambda_i \mathbf{u}_i \mathbf{v}_i^\top \right) \left( \sum_{i=1}^r \alpha'_i \mathbf{v}_i \right) \right\|^2 + \xi^2 \left\| \sum_{i=1}^m \alpha'_i \mathbf{v}_i \right\|^2 \\ &= \left\| \sum_{i=1}^n \beta'_i \mathbf{u}_i - \sum_{i=1}^r \lambda_i \alpha'_i \mathbf{u}_i \right\|^2 + \xi^2 \left\| \sum_{i=1}^m \alpha'_i \mathbf{v}_i \right\|^2 \\ &= \sum_{i=1}^r (\beta_i - \lambda_i \alpha_i)^2 + \sum_{i=r+1}^n \beta_i^2 + \xi^2 \sum_{i=1}^m \alpha_i'^2 \end{aligned} \quad (23)$$

$$\therefore \frac{\partial \Psi_C}{\partial \alpha'_i} = - \sum_{i=1}^r 2\lambda_i (\beta'_i - \lambda_i \alpha'_i) + \xi^2 \sum_{i=1}^m 2\alpha'_i = 0 \quad (24)$$

したがって,  $\Psi_C$  が最小になる  $\alpha'_i$  は以下を満たす:

$$\lambda_i \beta'_i = \lambda_i^2 \alpha'_i + \xi^2 \alpha'_i \quad (i \leq r), \quad \alpha'_i = 0 \quad (i > r) \quad (25)$$

したがって,

$$\alpha'_i = \frac{\lambda_i \beta'_i}{\lambda_i^2 + \xi^2} \quad (i \leq r), \quad \alpha'_i = 0 \quad (i > r). \quad (26)$$

$\lambda_{r+1} = \dots = \lambda_m = 0$  とおくと,  $i > r$  の場合も含めて,

$$\alpha'_i = \frac{\lambda_i \beta'_i}{\lambda_i^2 + \xi^2} \quad (27)$$

と書け,  $\Psi_C$  を最小とする  $\hat{\mathbf{x}}$  は

$$\hat{\mathbf{x}} = \bar{\mathbf{x}}_b + \sum_{i=1}^m \frac{\lambda_i \beta'_i}{\lambda_i^2 + \xi^2} \mathbf{v}_i. \quad (28)$$

式 (28) において,

- $\lambda_i^2 \gg \xi^2$  となる項は, 最小二乗解とほぼ同じとなり,
- $\lambda_i^2 \ll \xi^2$  となる項は, ほぼ 0 になる.


したがって, 拘束条件を付けた場合は,  $\lambda_i^2$  が小さい項が無視され, 解を安定化させる効果が得られる.

## ベイズ推定による方法

### ベイズの定理

予想をつけておいた上で、実データを参照して修正するという考え方は、ベイズの定理を用いて表現することもできる。

$$p(x|y) = \frac{p(y|x)p(x)}{\int p(y|x)p(x) dx}. \quad (29)$$



- ある事象  $A$  が起こったとき、考えられる原因を  $B_1, B_2, \dots, B_n$  とする。
- 原因  $B_j$  が与えられたとき、結果が  $A$  となる確率  $P(A|B_i)$  はわかっているとする。
- $B_1, \dots, B_n$  は互いに排反 (同時には起こり得ない) で、かつ  $B_1, \dots, B_n$  で考えられるすべての場合が考慮されているとする。
- このとき、原因が  $B_i$  である確率は

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{P(A)} = \frac{P(A|B_i)P(B_i)}{\sum_j P(A|B_j)P(B_j)}. \quad (30)$$

(事前情報  $p(B_j)$  が与えられれば、観測  $A$  から原因を推定可能。)

- 連続量の場合に以下の形になる。

$$p(x|y) = \frac{p(y|x)p(x)}{p(y)} = \frac{p(y|x)p(x)}{\int p(y|x)p(x) dx} \quad (31)$$

ベイズの定理  $p(x|y) = \frac{p(y|x)p(x)}{\int p(y|x)p(x) dx}$  において、

- $p(x)$  は、 $x$  に関する事前の予想を表す。(事前分布と呼ぶ)。
- $p(y|x)$  は、 $x$  がこの値だったら、このくらいの確率で  $y$  が観測されるということを表す。(また、観測への  $x$  の当てはまり具合を表している面もある。)
- $p(x|y)$  は、与えられた観測  $y$  の下で  $x$  を推定したもの。(事後分布と呼ぶ。)

## ベイズの定理に基づく推定

ここでは、ベイズの定理

$$p(\mathbf{x}|\mathbf{y}) = \frac{p(\mathbf{y}|\mathbf{x})p(\mathbf{x})}{\int p(\mathbf{y}|\mathbf{x})p(\mathbf{x}) d\mathbf{x}} \quad (32)$$

において、 $p(\mathbf{x})$ ,  $p(\mathbf{y}|\mathbf{x})$  がガウス分布に従うと仮定して、

$$p(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^m |\mathbf{P}_b|}} \exp\left(-\frac{1}{2}(\mathbf{x} - \bar{\mathbf{x}}_b)^\top \mathbf{P}_b^{-1}(\mathbf{x} - \bar{\mathbf{x}}_b)\right), \quad (33)$$

$$p(\mathbf{y}|\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^n |\mathbf{R}|}} \exp\left(-\frac{1}{2}(\mathbf{y} - \mathbf{H}\mathbf{x})^\top \mathbf{R}^{-1}(\mathbf{y} - \mathbf{H}\mathbf{x})\right), \quad (34)$$

とする。上の式に代入すると、以下が満たされることが分かる:

$$p(\mathbf{x}|\mathbf{y}) \propto \exp\left(-\frac{1}{2}(\mathbf{x} - \bar{\mathbf{x}}_b)^\top \mathbf{P}_b^{-1}(\mathbf{x} - \bar{\mathbf{x}}_b) - \frac{1}{2}(\mathbf{y} - \mathbf{H}\mathbf{x})^\top \mathbf{R}^{-1}(\mathbf{y} - \mathbf{H}\mathbf{x})\right). \quad (35)$$

$\mathbf{x}$  を推定するには、事後確率  $p(\mathbf{x}|\mathbf{y})$  の平均、あるいは事後確率を最大化する  $\mathbf{x}$  を求めるのが、よく使われる手段。(ガウス分布を仮定するとどちらも同じ。)  $p(\mathbf{x}|\mathbf{y})$  の  $\exp$  の指数部分を  $-\Psi_B/2$  とおくと、

$$-\frac{1}{2}(\mathbf{x} - \bar{\mathbf{x}}_b)^\top \mathbf{P}_b^{-1}(\mathbf{x} - \bar{\mathbf{x}}_b) - \frac{1}{2}(\mathbf{y} - \mathbf{H}\mathbf{x})^\top \mathbf{R}^{-1}(\mathbf{y} - \mathbf{H}\mathbf{x}) \quad (36)$$

を最大にする  $\mathbf{x}$  が、 $p(\mathbf{x}|\mathbf{y})$  を最大にする  $\mathbf{x}$  となる。

以下、しばらくの間、 $\mathbf{P}_b$ ,  $\mathbf{R}$  は正定値行列 (0 固有値を持たない) とする (分散共分散行列が 0 固有値を持つ場合、逆行列が存在しなくなって都合が悪い)。拘束付き最小二乗法の目的関数

$$\Psi_C = \|\mathbf{y} - \mathbf{H}\mathbf{x}\|^2 + \xi^2 \|\mathbf{x} - \bar{\mathbf{x}}_b\|^2$$

は、ベイズの定理から得た

$$\Psi_B = (\mathbf{x} - \bar{\mathbf{x}}_b)^\top \mathbf{P}_b^{-1}(\mathbf{x} - \bar{\mathbf{x}}_b) + (\mathbf{y} - \mathbf{H}\mathbf{x})^\top \mathbf{R}^{-1}(\mathbf{y} - \mathbf{H}\mathbf{x})$$

において、 $\mathbf{P}_b = \xi^{-2} \mathbf{I}$  かつ  $\mathbf{R} = \mathbf{I}$  とした場合と等価。  $\Psi_B$  は  $\Psi_C$  の一般化になっており、 $\Psi_B$  の方が予測の確度、観測の確度の情報を柔軟に取り入れられるのが利点。

例えば、 $\mathbf{x}$  の  $i$  番目の要素  $x_i$  に関する予想の不確かさの幅を  $\zeta_i$ 、 $\mathbf{y}$  の  $i$  番目の要素  $y_i$  の不確かさの幅を  $\sigma_i$  で表し、 $\mathbf{x}, \mathbf{y}$  の異なる要素の間に事前に想定される相関がないものとするれば、

$$\mathbf{P}_b = \begin{pmatrix} \zeta_1^2 & & \mathbf{0} \\ & \zeta_2^2 & \\ & & \ddots \\ \mathbf{0} & & & \zeta_m^2 \end{pmatrix}, \quad \mathbf{R} = \begin{pmatrix} \sigma_1^2 & & \mathbf{0} \\ & \sigma_2^2 & \\ & & \ddots \\ \mathbf{0} & & & \sigma_m^2 \end{pmatrix} \quad (37)$$

のように  $\mathbf{P}_b, \mathbf{R}$  はそれぞれ対角行列で書ける。このとき  $\Psi_B$  は

$$\Psi_B = \sum_{i=1}^m \zeta_i^{-2} (x_i - \bar{x}_{b,i})^2 + \sum_{i=1}^n \sigma_i^{-2} \left( y_i - \sum_{j=1}^m H_{ij} x_{b,j} \right)^2. \quad (38)$$

$\mathbf{x}, \mathbf{y}$  の各要素が不確かさの逆数で重みづけされており、不確かさの小さい (信用できる) 情報ほど大きな重みがついている。したがって、 $\Psi_B$  を最小化すると、信用できる情報をより重視した推定値が得られる。

$$\Psi_B = (\mathbf{x} - \bar{\mathbf{x}}_b)^\top \mathbf{P}_b^{-1} (\mathbf{x} - \bar{\mathbf{x}}_b) + (\mathbf{y} - \mathbf{H}\mathbf{x})^\top \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H}\mathbf{x})$$

は、以下の形に変形できる:

$$\Psi_B = (\mathbf{x} - \hat{\mathbf{x}})^\top (\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H}) (\mathbf{x} - \hat{\mathbf{x}}) + A. \quad (39)$$

但し、 $A$  は  $\mathbf{x}$  によらない定数、 $\hat{\mathbf{x}}$  は  $(\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H})\hat{\mathbf{x}} = \mathbf{P}_b^{-1} \bar{\mathbf{x}}_b + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{y}$  を満たすベクトル.

$\hat{\mathbf{x}}$  については,

$$\begin{aligned} (\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H})\hat{\mathbf{x}} &= \mathbf{P}_b^{-1} \bar{\mathbf{x}}_b + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{y} \\ &= (\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H})\bar{\mathbf{x}}_b + \mathbf{H}^\top \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H}\bar{\mathbf{x}}_b) \end{aligned} \quad (40)$$

より、以下のように求められる:

$$\hat{\mathbf{x}} = \bar{\mathbf{x}}_b + (\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H})^{-1} \mathbf{H}^\top \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H}\bar{\mathbf{x}}_b). \quad (41)$$

但し、分散共分散行列  $\mathbf{P}_b$ ,  $\mathbf{R}$  を正定値対称行列としたので、 $\mathbf{P}_b^{-1}$ ,  $\mathbf{R}^{-1}$  も正定値対称行列で、 $\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H}$  も正定値対称行列となり、 $\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H}$  が逆行列を持つことに注意.

$$\begin{aligned} -\frac{\Psi_B}{2} &= -\frac{1}{2} (\mathbf{x} - \bar{\mathbf{x}}_b)^\top \mathbf{P}_b^{-1} (\mathbf{x} - \bar{\mathbf{x}}_b) - \frac{1}{2} (\mathbf{y} - \mathbf{H}\mathbf{x})^\top \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H}\mathbf{x}) \\ &= -\frac{1}{2} (\mathbf{x} - \hat{\mathbf{x}})^\top (\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H}) (\mathbf{x} - \hat{\mathbf{x}}) - A. \end{aligned}$$

から、 $\hat{\mathbf{P}} = (\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H})^{-1}$  とおくと、事後分布  $p(\mathbf{x}|\mathbf{y})$  は,

$$p(\mathbf{x}|\mathbf{y}) \propto \exp\left(-\frac{1}{2} (\mathbf{x} - \hat{\mathbf{x}})^\top \hat{\mathbf{P}}^{-1} (\mathbf{x} - \hat{\mathbf{x}})\right) \quad (42)$$

を満たすことがわかる. したがって、 $p(\mathbf{x}|\mathbf{y})$  は、平均ベクトル  $\hat{\mathbf{x}}$ 、分散共分散行列  $(\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H})^{-1}$  のガウス分布になる.

分散共分散行列については,

$$\hat{\mathbf{P}} = (\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H})^{-1} = \mathbf{P}_b - \mathbf{P}_b \mathbf{H}^\top (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} \mathbf{H} \mathbf{P}_b \quad (43)$$

とも変形できる. このことは,

$$\begin{aligned} &(\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H}) \left[ \mathbf{P}_b - \mathbf{P}_b \mathbf{H}^\top (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} \mathbf{H} \mathbf{P}_b \right] \\ &= \mathbf{I} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H} \mathbf{P}_b - \mathbf{H}^\top (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} \mathbf{H} \mathbf{P}_b - \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H} \mathbf{P}_b \mathbf{H}^\top (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} \mathbf{H} \mathbf{P}_b \\ &= \mathbf{I} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H} \mathbf{P}_b - \mathbf{H}^\top \mathbf{R}^{-1} (\mathbf{R} + \mathbf{H} \mathbf{P}_b \mathbf{H}^\top) (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} \mathbf{H} \mathbf{P}_b = \mathbf{I} \end{aligned} \quad (44)$$

となることから確認できる.

また、平均ベクトルの式,

$$\hat{\mathbf{x}} = \bar{\mathbf{x}}_b + (\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H})^{-1} \mathbf{H}^\top \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H}\bar{\mathbf{x}}_b). \quad (45)$$

は,

$$(\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H})^{-1} = \mathbf{P}_b - \mathbf{P}_b \mathbf{H}^\top (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} \mathbf{H} \mathbf{P}_b \quad (46)$$



を代入すると、以下のように変形できる:

$$\begin{aligned}
\hat{\mathbf{x}} &= \bar{\mathbf{x}}_b + [\mathbf{P}_b - \mathbf{P}_b \mathbf{H}^\top (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} \mathbf{H} \mathbf{P}_b] \mathbf{H}^\top \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H} \bar{\mathbf{x}}_b) \\
&= \bar{\mathbf{x}}_b + \mathbf{P}_b \mathbf{H}^\top [\mathbf{I} - (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} \mathbf{H} \mathbf{P}_b \mathbf{H}^\top] \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H} \bar{\mathbf{x}}_b) \\
&= \bar{\mathbf{x}}_b + \mathbf{P}_b \mathbf{H}^\top (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} [(\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R}) - \mathbf{H} \mathbf{P}_b \mathbf{H}^\top] \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H} \bar{\mathbf{x}}_b) \\
&= \bar{\mathbf{x}}_b + \mathbf{P}_b \mathbf{H}^\top (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} (\mathbf{y} - \mathbf{H} \bar{\mathbf{x}}_b).
\end{aligned}$$

$\dim \mathbf{x} > \dim \mathbf{y}$  の場合には、こちらの方が便利である。後で出てくるカルマンフィルタでもこの式を使う。

### ベイズの定理に基づく推定 (まとめ)

$p(\mathbf{x}) = \mathcal{N}(\bar{\mathbf{x}}_b, \mathbf{P}_b)$ ,  $p(\mathbf{y}|\mathbf{x}) = \mathcal{N}(\mathbf{H}\mathbf{x}, \mathbf{R})$  のとき、事後分布  $p(\mathbf{x}|\mathbf{y})$  もガウス分布となり、平均ベクトル、分散共分散行列は以下ようになる。

- 平均ベクトル:

$$\begin{aligned}
\hat{\mathbf{x}} &= \bar{\mathbf{x}}_b + (\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H})^{-1} \mathbf{H}^\top \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H} \bar{\mathbf{x}}_b) \\
&= \bar{\mathbf{x}}_b + \mathbf{P}_b \mathbf{H}^\top (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} (\mathbf{y} - \mathbf{H} \bar{\mathbf{x}}_b),
\end{aligned} \tag{47}$$

- 分散共分散行列:

$$\begin{aligned}
\hat{\mathbf{P}} &= (\mathbf{P}_b^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H})^{-1} \\
&= \mathbf{P}_b - \mathbf{P}_b \mathbf{H}^\top (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} \mathbf{H} \mathbf{P}_b
\end{aligned} \tag{48}$$

なお、このベイズ推定の式

$$\begin{aligned}
\hat{\mathbf{x}} &= \bar{\mathbf{x}}_b + \mathbf{P}_b \mathbf{H}^\top (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} (\mathbf{y} - \mathbf{H} \bar{\mathbf{x}}_b), \\
\hat{\mathbf{P}} &= \mathbf{P}_b - \mathbf{P}_b \mathbf{H}^\top (\mathbf{H} \mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} \mathbf{H} \mathbf{P}_b
\end{aligned}$$

は、データ同化では最適内挿法と呼ばれる手法に相当する。実際に使用する際には、 $\mathbf{P}_b$  や  $\mathbf{R}$  の設計が問題になる。 $\mathbf{P}_b$  については、グリッド点間の距離の関数

$$\sigma^2 \exp \left[ -\frac{\|\mathbf{z}_i - \mathbf{z}_j\|^2}{2\ell^2} \right] \tag{49}$$

のようなものを使うこともある。

### 補足

なお、途中で使った、

$$(\mathbf{P}^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H})^{-1} \mathbf{H}^\top \mathbf{R}^{-1} = \mathbf{P} \mathbf{H}^\top (\mathbf{H} \mathbf{P} \mathbf{H}^\top + \mathbf{R})^{-1}, \tag{50a}$$

$$(\mathbf{P}^{-1} + \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H})^{-1} = \mathbf{P} - \mathbf{P} \mathbf{H}^\top (\mathbf{H} \mathbf{P} \mathbf{H}^\top + \mathbf{R})^{-1} \mathbf{H} \mathbf{P} \tag{50b}$$

という公式は、逆行列補題、Sherman-Morrison-Woodbury 公式などと呼ばれ、このあと、何度か出てくる。

### $\mathbf{P}_b$ が 0 固有値を持つ場合

$\mathbf{x}$  の事前分布の分散共分散行列  $\mathbf{P}_b$  が 0 固有値を持つ場合、 $\mathbf{P}_b = \check{\mathbf{U}}\check{\mathbf{\Lambda}}\check{\mathbf{U}}^\top$  のように固有値分解し、

$$\mathbf{x} = \bar{\mathbf{x}}_b + \check{\mathbf{U}}\mathbf{z} \quad (51)$$

とすれば、ガウス分布  $\mathcal{N}(\mathbf{0}, \check{\mathbf{\Lambda}})$  に従う確率変数  $\mathbf{z}$  を使って  $\mathbf{x}$  を表現することができる。

(ここでは、 $\check{\mathbf{\Lambda}}$  が正定値 (正則) になるように 0 の固有値に対応する成分を削った、

$$\mathbf{P}_b = \check{\mathbf{U}}\check{\mathbf{\Lambda}}\check{\mathbf{U}}^\top = (\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r) \begin{pmatrix} \lambda_1 & & \mathbf{0} \\ & \ddots & \\ \mathbf{0} & & \lambda_r \end{pmatrix} (\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r)^\top \quad (52)$$

の方を使う。)

ガウス分布  $\mathcal{N}(\mathbf{0}, \check{\mathbf{\Lambda}})$  に従う確率変数  $\mathbf{z}$  を使い、 $\mathbf{x}$  を

$$\mathbf{x} = \bar{\mathbf{x}}_b + \check{\mathbf{U}}\mathbf{z} \quad (53)$$

のように表現したとき、

$$p(\mathbf{z}) = \frac{1}{\sqrt{(2\pi)^r}} \exp\left(-\frac{1}{2}\mathbf{z}^\top \check{\mathbf{\Lambda}}^{-1}\mathbf{z}\right), \quad (54)$$

$$p(\mathbf{y}|\mathbf{z}) = \frac{1}{\sqrt{(2\pi)^n |\mathbf{R}|}} \exp\left(-\frac{1}{2}(\mathbf{y} - \mathbf{H}\bar{\mathbf{x}}_b - \mathbf{H}\check{\mathbf{U}}\mathbf{z})^\top \mathbf{R}^{-1}(\mathbf{y} - \mathbf{H}\bar{\mathbf{x}}_b - \mathbf{H}\check{\mathbf{U}}\mathbf{z})\right), \quad (55)$$

の下で、 $\mathbf{z}$  の事後分布を求めればよい ( $\mathbf{\Lambda}$  は正則なので、 $\mathbf{z}$  の確率密度関数が定義できる)。

$\mathbf{z}$  の分散共分散行列  $\check{\mathbf{\Lambda}}$  は正定値なので、 $\mathbf{z}$  の事後分布の平均は、先程の式から直ちに求まる。

$$\hat{\mathbf{z}} = (\check{\mathbf{\Lambda}}^{-1} + \check{\mathbf{U}}^\top \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H} \check{\mathbf{U}})^{-1} \check{\mathbf{U}}^\top \mathbf{H}^\top \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H}\bar{\mathbf{x}}_b). \quad (56)$$

両辺に左から  $\check{\mathbf{U}}$  を掛けた上で変形すると、

$$\begin{aligned} \check{\mathbf{U}}\hat{\mathbf{z}} &= \check{\mathbf{U}}(\check{\mathbf{\Lambda}}^{-1} + \check{\mathbf{U}}^\top \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H} \check{\mathbf{U}})^{-1} \check{\mathbf{U}}^\top \mathbf{H}^\top \mathbf{R}^{-1} (\mathbf{y} - \mathbf{H}\bar{\mathbf{x}}_b) \\ &= \check{\mathbf{U}}\check{\mathbf{\Lambda}}\check{\mathbf{U}}^\top \mathbf{H}^\top (\mathbf{H}\check{\mathbf{U}}\check{\mathbf{\Lambda}}\check{\mathbf{U}}^\top \mathbf{H}^\top + \mathbf{R})^{-1} (\mathbf{y} - \mathbf{H}\bar{\mathbf{x}}_b) \\ &= \mathbf{P}_b \mathbf{H}^\top (\mathbf{H}\mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} (\mathbf{y} - \mathbf{H}\bar{\mathbf{x}}_b) \end{aligned} \quad (57)$$

したがって、

$$\hat{\mathbf{x}} = \bar{\mathbf{x}}_b + \mathbf{P}_b \mathbf{H}^\top (\mathbf{H}\mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} (\mathbf{y} - \mathbf{H}\bar{\mathbf{x}}_b). \quad (58)$$

$\mathbf{z}$  の事後分布の分散共分散行列も、先程の式から

$$\hat{\mathbf{P}}_z = (\check{\mathbf{\Lambda}}^{-1} - \check{\mathbf{U}}^\top \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H} \check{\mathbf{U}})^{-1} \quad (59)$$

となるので、両辺の両側から  $\check{\mathbf{U}}$  を掛けた上で変形すると、

$$\begin{aligned} \hat{\mathbf{P}} &= \check{\mathbf{U}}\hat{\mathbf{P}}_z\check{\mathbf{U}}^\top = \check{\mathbf{U}}(\check{\mathbf{\Lambda}}^{-1} - \check{\mathbf{U}}^\top \mathbf{H}^\top \mathbf{R}^{-1} \mathbf{H} \check{\mathbf{U}})^{-1} \check{\mathbf{U}}^\top \\ &= \check{\mathbf{U}}[\check{\mathbf{\Lambda}} - \check{\mathbf{\Lambda}}\check{\mathbf{U}}^\top \mathbf{H}^\top (\mathbf{H}\check{\mathbf{U}}\check{\mathbf{\Lambda}}\check{\mathbf{U}}^\top \mathbf{H}^\top + \mathbf{R})^{-1} \mathbf{H}\check{\mathbf{U}}\check{\mathbf{\Lambda}}]\check{\mathbf{U}}^\top \\ &= \check{\mathbf{U}}\check{\mathbf{\Lambda}}\check{\mathbf{U}}^\top - \check{\mathbf{U}}\check{\mathbf{\Lambda}}\check{\mathbf{U}}^\top \mathbf{H}^\top (\mathbf{H}\check{\mathbf{U}}\check{\mathbf{\Lambda}}\check{\mathbf{U}}^\top \mathbf{H}^\top + \mathbf{R})^{-1} \mathbf{H}\check{\mathbf{U}}\check{\mathbf{\Lambda}}\check{\mathbf{U}}^\top \\ &= \mathbf{P}_b - \mathbf{P}_b \mathbf{H}^\top (\mathbf{H}\mathbf{P}_b \mathbf{H}^\top + \mathbf{R})^{-1} \mathbf{H}\mathbf{P}_b \end{aligned} \quad (60)$$

つまり、正則の場合の平均ベクトル、分散共分散行列の式を非正則な場合に適用しても問題ない。